

Metaheurísticas

Práctica 3 – Algoritmos meméticos

Grupo 3 – Martes 12:30-14:30

43180612K - Abad Vich, David

DAV00004@RED.UJAEN.ES

GRADO EN INGENIERÍA INFORMÁTICA Curso 2014/2015

Índice

1 CONTENIDOS DEL ARCHIVO

2	Descripción del problema	2
3	Aplicación de los algoritmos	3
4	Algoritmos utilizados	7
4.1	Búsqueda local	7
4.2	AGG – Algoritmo Genético Generacional (Base para meméticos)	9
4.2.1	AM - (10,1.0)	9
4.2.2	AM – (10,0.1).....	10
4.2.3	AM – (10,0.1mej)	10
5	Algoritmo de comparación – Greedy.....	11
6	Procedimiento considerado para el desarrollo de la práctica	12
6.1	Pequeño manual de usuario.....	12
7	Experimentos y análisis de resultados.....	13
7.1	Resultados Greedy	14
7.2	Resultados Búsqueda Local.....	15
7.3	Resultados AM – (10,1.0).....	16
7.4	Resultados AM – (10,0.1).....	17
7.5	Resultados AM – (10,0.1mej).....	18
7.6	Resultados Globales.....	19
8	Bibliografía	21

2 DESCRIPCIÓN DEL PROBLEMA

De forma general, se trata de encontrar una solución al problema de asignación cuadrática (del inglés, Quadratic Assignment Problem o QAP).

Para este problema, disponemos de n unidades y localizaciones, de modo que debemos asignar, de manera óptima, las unidades a las localizaciones. Para ello se dispone de un método para evaluar cómo de óptima es una solución y es mediante el flujo que hay entre diferentes unidades y la distancia que hay entre las localizaciones.

Sin embargo la descripción de encontrar una solución es bastante genérica. Debido a la cantidad de tiempo que nos puede llevar el conseguir la solución más óptima, dependiendo del tamaño del problema, en ocasiones nos tendremos que conformar con encontrar una solución, óptima por supuesto, pero no la más óptima que exista.

Entonces, el coste de una solución se puede formular como:

$$\pi \in \prod_N \left(\sum_{i=1}^n \sum_{j=1}^n f_{ij} \cdot d_{\pi(i)\pi(j)} \right)$$

donde:

- π es una permutación solución al problema, que representa la asignación de la unidad i a la localización $\pi(i)$.
- f_{ij} es el flujo que hay de la unidad i a la j .
- d_{kl} es la distancia existente entre la localización k y la l .

Para este problema se usarán 20 casos diferentes, seleccionados de varios conjuntos de instancias disponibles en la QAPLIB (la biblioteca de problemas de asignación cuadrática) donde se puede encontrar además una descripción de lo que representa el problema.

3 APLICACIÓN DE LOS ALGORITMOS

Al aplicar los algoritmos al problema, hay que tener en común varios aspectos:

- Representación del problema: El problema se representa como dos matrices, una que contiene los flujos y otra las distancias, de manera que se puede ver el flujo que hay entre dos unidades y la distancia entre dos localizaciones de forma inmediata. Hay que tener en cuenta que mientras que la distancia entre dos localizaciones es la misma en ambos sentidos, puede que el flujo sea distinto entre dos unidades, dependiendo del sentido.
- Representación de las soluciones: Hemos mencionado antes la representación para la solución y es utilizando una permutación de n elementos (siendo n el tamaño del problema) a modo de que cada posición de la permutación representa una unidad y cada elemento de la permutación representa su localización asignada:

$$\text{solución: } \begin{matrix} \text{unidad} & (1 & 2 & \dots & n) \\ \text{localización} & (i & j & \dots & k) \end{matrix} \quad i, j, k \in \{1, \dots, n\}$$

- Función objetivo: La función que se va a optimizar, es la suma del producto entre el flujo de dos unidades y la distancia de sus correspondientes localizaciones asignadas. Su pseudocódigo¹ es:

```
coste ← 0
tamaño ← tamaño(solución)
Para i ← 0 Hasta tamaño-1 Hacer
    Para j ← 0 Hasta tamaño-1 Hacer
        coste ← distancia[solución[i]][solución[j]] * flujo[i][j]
    Fin_Para
Fin_Para
```

- Generación de vecino: Para generar el entorno, se generarán los vecinos mediante el intercambio de dos elementos de la permutación solución.
- Función de factorización: Para un cálculo eficiente del coste de una solución, se extraerá del coste de la solución original los costes relacionados con las dos posiciones que se van a intercambiar para generar esa solución.
- Criterio de parada: Tras evaluar 10000 soluciones distintas, se detendrá la ejecución del algoritmo.
- Generación de la solución inicial aleatoria: En ambos algoritmos se utiliza la misma función para crear una solución inicial aleatoria de la que partir. El pseudocódigo es:

¹ Nota de programación: Hay que tener en cuenta que en el código los vectores y arrays empiezan desde la posición 0, por lo que queda representado en el pseudocódigo.

```

Función generarSolucionAleatoria() Devuelve un vector con la permutación
    tamaño ← tamaño del problema
    Para i ← 0 Hasta tamaño Hacer
        encontrada ← falso
        Mientras (no encontrada) Hacer
            crear localización aleatoria
            Para j ← 0 Hasta tamaño Hacer
                Si (localización está en el vector) Entonces
                    encontrada ← false
            Fin_Si
        Fin_Para
        vector[i] ← localización
    Fin_Mientras
    Fin_para
    Devolver vector
Fin_Función

```

- Mecanismo de selección considerado: El método para seleccionar a los padres consiste en un torneo binario, en el cual se seleccionan a dos padres para que compitan, obteniendo al final un solo ganador.

```

Función torneoBinario(padre1, padre2) Devuelve vector con la permutación del ganador
    Si (coste(padre1) < coste(padre2)) Entonces
        Devolver vector(padre1)
    Si_No
        Devolver vector(padre2)
    Fin_Si
Fin_Función

```

- Operadores de cruce: Operador de posición, que mantiene los elementos comunes de los padres y reordena el resto.

```

Función cruzaPadresPosición(padre1, padre2) Devuelve vector con el cruce
    tamaño ← tamaño(padre1)
    pos ← 0
    hijo ← llenar(-1)
    Para i ← 0 Hasta tamaño Hacer
        Si (padre1[i] == padre2[i]) Entonces
            hijo[i] ← padre1[i]
        Si_No
            no_asignados ← añade(padre1[i])
        Fin_Si
    Fin_Para
    Mientras (tamaño(no_asignados) > 0) Hacer
        Si (hijo[pos] == -1) Entonces
            gen ← extraer_aleatorio(no_asignados)
            hijo[pos] ← gen
        Fin_Si
        pos++
    Fin_Mientras
    Devolver hijo
Fin_Función

```

Operador de cruce OX, que toma una cadena central del primer padre y el resto de elementos, los toma siguiendo el orden del otro padre.

```
Función cruceOX(padre1, padre2) Devuelve vector con el cruce
    tamaño ← tamaño(padre1)
    hijo ← llenar(-1)
    inicio ← random(tamaño/2)
    fin ← inicio + tamaño/2
    Para  $i \leftarrow$  inicio Hasta fin Hacer
        hijo[i] ← padre1[i]
    Fin_Para
    Para  $i \leftarrow$  0 Hasta tamaño Hacer
        está ← false
        Para  $j \leftarrow$  inicio Hasta fin Hacer
            Si (padre2[i] == hijo[i]) Entonces
                está ← true
            Fin_Si
            Si (No está) Entonces
                elementos ← añadir(padre2[i])
            Fin_Si
        Fin_Para
    Fin_Para
    Para  $i \leftarrow$  0 Hasta tamaño Hacer
        Si (hijo[i] == -1) Entonces
            hijo[i] ← sacar primero(elementos)
        Fin_Si
    Fin_Para
    Devolver hijo
Fin_Funcion
```

4 ALGORITMOS UTILIZADOS

4.1 BÚSQUEDA LOCAL

Generamos una solución inicial aleatoria y exploramos el entorno, siguiendo la técnica del primer mejor, por lo que en cuanto encontramos una solución mejor, nos movemos a ella. El entorno se recorre

```
Procedimiento buscar()
  Generar solución inicial aleatoria
  tamaño ← tamaño(solución)
  Crear e inicializar array don't look bits dlb
  i ← 0
  mejora ← true
  Mientras (mejora AND soluciones_comprobadas < 10000) Hacer
    j ← i+1
    solución encontrada ← false
    Si (dlb[i] != 0) Entonces
      //Si el elemento está desactivado, no entra en el siguiente bucle
      encontrada ← true
    Fin_Si
    Mientras (j < tamaño AND no encontrada) Hacer
      soluciones_comprobadas++
      coste ← calcular el coste de cambiar las posiciones i y j
      Si (coste < coste de la solución) Entonces
        Se activa el elemento con dlb[i] ← 0
        Se cambia la solución actual por la encontrada
        encontrada ← true
      i ← 0
    Fin_Si
    j++
  Fin_Mientras
  Si (no encontrada) Entonces
    Se desactiva el elemento con dlb[i] ← 1
  Fin_Si
  Si (i == tamaño - 1) Entonces
    //Si ya ha recorrido todos los elementos, es que no hay mejora
    mejora ← false
  Fin_Si
  i++
Fin_Mientras
Fin_Procedimiento
```


además de forma secuencial con la ayuda de la máscara *don't look bits*, por lo que se exploran sólo las unidades que están activas. Pseudocódigo:

En la búsqueda local, además de parar tras comprobar 10000 soluciones, también hay otro criterio de parada y es cuando no hay posibilidad de mejora en el entorno.

No habrá posibilidad de mejora cuando ya se han comprobado todos los cambios posibles, por lo que también la máscara se encontrará a 1 en todos sus bits (todos activados ya que no ha habido mejora para ninguno de los intercambios posibles).

4.2 AGG – ALGORITMO GENÉTICO GENERACIONAL (BASE PARA MEMÉTICOS)

Primero se realiza el cálculo de la cantidad de padres que se van a cruzar, según la probabilidad de cruce, y la cantidad de genes que se van a mutar, dependiendo de su respectiva probabilidad de mutación.

Se crea la generación 0 de forma aleatoria (con la función previamente descrita) y empieza el bucle.

En el bucle se siguen los pasos del algoritmo de: seleccionar, cruzar, mutar y reemplazar.

- **Selección:** Se realizan 50 torneos binarios entre padres escogidos aleatoriamente de la generación actual, que formarán la base de la nueva generación.
- **Cruce:** Se cruzan la cantidad esperada de padres, dos a dos, en orden, empezando desde el primero. El cruce realizado es el OX, generando dos hijos por cada cruce.
- **Mutación:** Se realizan la cantidad esperada de mutaciones, escogiendo aleatoriamente el cromosoma al que se le aplica y luego escogiendo dos posiciones aleatorias para el intercambio.
- **Reemplazamiento:** Se evalúa la nueva generación y antes de sustituir, se busca al mejor de la generación actual. Se sustituyen entonces los n primeros padres, comprobando que estamos quedándonos con el mejor.

Se repite hasta que se ha evaluado la función objetivo tantas veces como las indicadas (por defecto 20.000).

4.2.1 AM - (10,1.0)

Esta versión aplica, cada diez generaciones, la búsqueda local sobre toda la población. Es decir, individualmente se aplica la BL con probabilidad 1.0.

Añade una pequeña condición al código base del algoritmo:

```
Si (contador == 10) Entonces
    Si (tipo == 0) Entonces
        Para  $j \leftarrow 0$  Hasta tamaño(generación) Hacer
            Aplicar BL sobre cromosoma  $j$ 
        Fin_Para
    Fin_Si
Fin_Si
```

4.2.2 AM – (10,0.1)

Esta variante aplica la BL, cada diez generaciones, a un subconjunto de cromosomas seleccionados con la probabilidad 0.1. En mi caso, se recorre el vector de cromosomas y con probabilidad 0.1 se aplica la BL a cada uno.

```
Si (contador == 10) Entonces
    Si (tipo == 1) Entonces
        Para  $j \leftarrow 0$  Hasta tamaño(generación) Hacer
            elegido  $\leftarrow$  Aleatorio entre 0 y 99
            Si (elegido  $\leq$  10) Entonces
                Aplicar BL sobre cromosoma  $j$ 
            Fin_Si
        Fin_Para
    Fin_Si
Fin_Si
```

4.2.3 AM – (10,0.1mej)

Similar al anterior, pero ahora aplica la BL a los $0.1 * N$ mejores cromosomas.

```
Si (contador == 10) Entonces
    Si (tipo == 2) Entonces
        sub  $\leftarrow 0.1 * \text{tamaño(generación)}$ 
        Ordenar_vector (generación)
        Para  $j \leftarrow 0$  Hasta sub Hacer
            Aplicar BL sobre cromosoma  $j$ 
        Fin_Para
        Mezclar_vector (generación)
    Fin_Si
Fin_Si
```

5 ALGORITMO DE COMPARACIÓN – GREEDY

Este algoritmo está basado en la búsqueda del primer mejor. Consiste en realizar el sumatorio de cada fila de ambas matrices (flujos y distancias) y asignar a los mayores flujos, las menores distancias.

Es un algoritmo de bajo coste computacional, pues genera una solución (que variará según se asignen las localizaciones a las unidades) que normalmente no llegará a ser un óptimo, pero es probable que se encuentre cerca de uno, por lo que puede tener una gran aplicación si se utiliza para generar soluciones iniciales al problema, de las cuales explorar el entorno para encontrar una mejor solución.

```
Procedimiento CalcularSolucion()
    tamaño ← tamaño(distancias)
    Para i ← 0 Hasta tamaño-1 Hacer
        Para j ← 0 Hasta tamaño-1 Hacer
            suma_distancias[i] ← suma_distancias[i] + distancias[i][j]
            suma_flujos[i] ← suma_flujos[i] + flujos[i][j]
        Fin_Para
    Fin_Para
    Para i ← 0 Hasta tamaño-1 Hacer
        Para j ← 0 Hasta tamaño-1 Hacer
            Si (suma_flujos[i] > max) Entonces
                Coge nuevo flujo máximo
            Fin_Si
            Si (suma_distancias[i] < min AND suma_distancias[i] >= 0) Entonces
                Coge nueva distancia mínima
            Fin_Si
        Fin_Para
        solución[flujo máximo] = distancia mínima
        suma_flujos[flujo máximo] = -1
        suma_distancias[distancia mínima] = -1
    Fin_Para
Fin Procedimiento
```

Para generar la solución simplemente se suman los flujos y distancias y se asigna al mayor flujo, la menor distancia.

Para evitar volver a coger un elemento que ya ha sido asignado, se le asigna un valor negativo que pasará desapercibido cuando se busquen los siguientes valores máximo y mínimo.

6 PROCEDIMIENTO CONSIDERADO PARA EL DESARROLLO DE LA PRÁCTICA

Para el desarrollo de la práctica se ha utilizado código desarrollado por el propio alumno, con la ayuda de las transparencias de la asignatura y diferentes consultas al profesor.

Además, se han incorporado opciones extra para la práctica que pueden ayudar en el análisis de los resultados, tales como número de iteraciones o la posibilidad de usar la solución del algoritmo Greedy como solución inicial para ambas búsquedas.

6.1 PEQUEÑO MANUAL DE USUARIO

La ejecución del programa es sencilla:

1. Ejecutar el archivo Meta1a.exe situado en la carpeta Deployment.
2. Elegir el archivo a ejecutar.
3. Introducir los diferentes parámetros (opcional, se puede dejar por defecto):
 - a. Matriz que se lee primero (por defecto la de flujos).
 - b. Valor de la semilla para la generación de números aleatoria (por defecto 123456).
 - c. (Opcional) Elegir el número de evaluaciones de la función objetivo a realizar para los algoritmos genéticos.
4. Hacer clic en ejecutar.

El programa incluye una pequeña barra de progreso, introducido de forma manual, para mostrar que la ejecución sigue activa.

También cabe la posibilidad de ejecutar el programa usando Qt, para ello, una vez instalado Qt, hay que abrir el proyecto que desde la pantalla de bienvenida de Qt, es haciendo clic en la opción Open Project, seleccionando la carpeta donde se encuentra el proyecto y seleccionando el archivo .pro que hay ahí.

Una vez abierto, construir y ejecutar. Saldrá entonces la misma interfaz que con el ejecutable y ya hay que seguir los mismos pasos que con el mismo.

NOTA: Es posible que con archivos de gran tamaño (como lipa90) el programa parece no responder, pero acaba la ejecución transcurridos unos segundos.

7 EXPERIMENTOS Y ANÁLISIS DE RESULTADOS

Para todos los problemas se ha considerado siempre el mismo valor para la semilla: 123456.

Pasamos a comentar las instancias usadas en esta práctica², todas partes de la QAPLIB:

- bur*: Tenemos una matriz que contiene el tiempo medio de escritura de una máquina de escribir y otra con la frecuencia de los pares de letras en diferentes idiomas.
- chr*: Nos dan una matriz de adyacencia de un árbol balanceado y otra matriz con grafos completos.
- els19: Las distancias entre 19 instalaciones diferentes de un hospital y el flujo de pacientes entre ellas. Hay que notar que ésta es de las instancias que tendrá que leerse primero la matriz de distancias.
- esc32a: Ejemplos de una aplicación, usados para circuitos secuenciales auto-comprobables.
- kra32: Contienen datos reales usados para planear el Hospital Regensburg en Alemania.
- lipa90a: Esta instancia proviene de generadores de problemas, que proveen de instancias asimétricas con soluciones óptimas conocidas.
- nug25: La matriz de distancias contiene las distancias de cuadrículas rectangulares de Manhattan. También hay que leer primero la matriz de distancias en esta instancia.
- sko*: Las distancias de éstos problemas son rectangulares y los flujos son número pseudoaleatorios. Otra más para la que se lee primero la matriz de distancias.
- tai*: Instancias uniformemente generadas. Asimétricas y aleatorias, suceden en la generación de patrones de grises.
- tho40: Las distancias de este problema son rectangulares, por lo que la primera matriz que se lee es la de distancias.

² En caso de no indicar nada, la matriz que se ha de leer primero es la de flujos.

7.1 RESULTADOS GREEDY

Algoritmo Greedy			
Caso	Coste obtenido	Desv	Tiempo
Els19	38627698	124,42	0,00
Chr20a	8632	293,80	0,00
Chr25a	17556	362,49	0,00
Nug25	4462	19,18	0,00
Bur26a	5968117	9,98	0,00
Bur26b	4273373	11,93	0,00
Tai30a	2098700	15,43	0,00
Tai30b	1387185541	117,73	0,00
Esc32a	342	163,08	0,00
Kra32	117130	32,05	0,00
Tai35a	2952758	21,91	0,00
Tai35b	506552163	78,79	0,00
Tho40	312578	29,96	0,00
Tai40a	3730054	18,82	0,00
Sko42	18902	19,54	0,00
Sko49	27378	17,07	0,00
Tai50a	5804880	17,54	1,00
Tai50b	788404422	71,83	0,00
Tai60a	8345630	15,82	1,00
Lipa90a	367797	1,99	1,00

7.2 RESULTADOS BÚSQUEDA LOCAL

Algoritmo BL			
Caso	Coste obtenido	Desv	Tiempo
Els19	23734354	37,89	1,00
Chr20a	3912	78,47	0,00
Chr25a	8028	111,49	2,00
Nug25	3962	5,82	1,00
Bur26a	5444522	0,33	2,00
Bur26b	3851727	0,89	2,00
Tai30a	1916134	5,39	2,00
Tai30b	691972163	8,61	3,00
Esc32a	170	30,77	3,00
Kra32	98630	11,20	5,00
Tai35a	2585098	6,73	5,00
Tai35b	353867912	24,90	5,00
Tho40	264608	10,02	9,00
Tai40a	3339928	6,39	8,00
Sko42	16234	2,67	11,00
Sko49	24972	6,78	22,00
Tai50a	5265454	6,61	19,00
Tai50b	487830146	6,32	34,00
Tai60a	7717196	7,09	37,00
Lipa90a	363582	0,82	227,00

7.3 RESULTADOS AM – (10,1.0)

Algoritmo AM - (10,1.0)			
Caso	Coste obtenido	Desv	Tiempo
Els19	24625852	43,07	46,00
Chr20a	3658	66,88	62,00
Chr25a	4776	25,82	78,00
Nug25	3872	3,42	63,00
Bur26a	5447858	0,39	78,00
Bur26b	3852519	0,91	63,00
Tai30a	1925598	5,91	94,00
Tai30b	756644792	18,76	78,00
Esc32a	150	15,38	78,00
Kra32	95280	7,42	78,00
Tai35a	2548254	5,21	94,00
Tai35b	333424419	17,69	94,00
Tho40	256510	6,65	110,00
Tai40a	3395354	8,15	109,00
Sko42	17564	11,08	141,00
Sko49	25844	10,51	140,00
Tai50a	5330856	7,94	156,00
Tai50b	539320588	17,54	140,00
Tai60a	7767814	7,80	219,00
Lipa90a	364877	1,18	499,00

7.4 RESULTADOS AM – (10,0.1)

Algoritmo AM - (10,0.1)			
Caso	Coste obtenido	Desv	Tiempo
Els19	20536394	19,31	32,00
Chr20a	3094	41,15	32,00
Chr25a	5040	32,77	47,00
Nug25	4116	9,94	46,00
Bur26a	5462462	0,66	47,00
Bur26b	3851966	0,89	46,00
Tai30a	1911426	5,13	62,00
Tai30b	755401574	18,57	63,00
Esc32a	154	18,46	62,00
Kra32	101940	14,93	78,00
Tai35a	2561476	5,76	78,00
Tai35b	329876671	16,43	78,00
Tho40	256018	6,45	109,00
Tai40a	3351004	6,74	94,00
Sko42	17538	10,92	93,00
Sko49	25426	8,72	156,00
Tai50a	5295558	7,22	141,00
Tai50b	522801374	13,94	156,00
Tai60a	7995072	10,95	202,00
Lipa90a	365487	1,35	452,00

7.5 RESULTADOS AM – (10,0.1MEJ)

Algoritmo AM - (10,0.1mej)			
Caso	Coste obtenido	Desv	Tiempo
Els19	23311566	35,43	31,00
Chr20a	3796	73,18	31,00
Chr25a	5906	55,58	47,00
Nug25	4058	8,39	47,00
Bur26a	5459672	0,61	47,00
Bur26b	3841088	0,61	47,00
Tai30a	1943238	6,88	63,00
Tai30b	801855529	25,86	62,00
Esc32a	184	41,54	63,00
Kra32	97470	9,89	63,00
Tai35a	2616472	8,03	78,00
Tai35b	352749159	24,51	78,00
Tho40	281248	16,94	93,00
Tai40a	3439412	9,56	109,00
Sko42	18160	14,85	109,00
Sko49	26458	13,14	141,00
Tai50a	5427836	9,90	140,00
Tai50b	654242759	42,59	141,00
Tai60a	7984118	10,80	203,00
Lipa90a	365765	1,42	453,00

7.6 RESULTADOS GLOBALES


<i>Algoritmo</i>	<i>Desviación</i>	<i>Tiempo (en ms.)</i>
<i>Greedy</i>	72.17	0.15
<i>BL</i>	18.46	19.90
<i>AM – (10,1.0)</i>	14.09	121.00
<i>AM – (10,0.1)</i>	12.51	103.70
<i>AM – (10,0.1mej)</i>	20.48	102.30

Se puede apreciar la mejora que supone el añadir una búsqueda local al anterior algoritmo genético, ya salen mejores resultados que con la búsqueda local, aunque no se puede decir lo mismo de la versión que aplica la mejora sólo a los mejores.

En ese último caso, la explicación es sencilla y es que cae rápidamente en un óptimo local, ya que al mejorar unos pocos cromosomas, que debido al tamaño estándar de la población será siempre uno, se consigue que ese uno sea el que vuelva a intentar mejorarse la próxima vez, sin mejora obviamente ya que fue mejorado previamente. Entonces el algoritmo tiene riesgo de caer en un ciclo en el que siempre va a intentar mejorar el mismo cromosoma³ y va a agotar todas sus evaluaciones en generar hijos, que al fin y al cabo no se van a mejorar.

A diferencia de los genéticos, estos algoritmos tienen un límite de mejora respecto a la cantidad de evaluaciones que se pueden hacer de la función objetivo. Esto es debido a que, por la aplicación de la búsqueda local, acaban quedándose en algún óptimo local, de manera que al principio se explora más, para acabar poco a poco centrándose en un área en la que se acabará encontrando el óptimo de esa área.

³ Hay que recordar que con el algoritmo, mantenemos siempre el mejor cromosoma obtenido.



8 BIBLIOGRAFÍA

- G. Ochoa, S. Verel y M. Tomassini. First-improvement vs. Best-improvement Local Optima Networks of NK Landscapes. *11th International Conference on Parallel Problem Solving From Nature*, Krakow, Poland, 2010.
- Loiola. A survey for the quadratic assignment problem. 2007